

Director

Demián Wassermann

Investigador Permanente Athena Project Team, INRIA

demian.wassermann@inria.fr

Alumno

Leonel Exequiel Gómez

LU: 436/07, UBA

leexgo1987@gmail.com

Resumen

La Resonancia Magnética de difusión (dMRI en inglés) es una técnica útil para generar imágenes de órganos internos del cuerpo, sin la necesidad de someter al mismo a un procedimiento quirúrgico. Las imágenes construidas por esta técnica están fuertemente relacionadas con la difusión de las partículas de agua en los tejidos. Estas proveen valiosa información sobre la micro-estructura de los diferentes tipos de tejidos del cerebro (LeBihan and Breton 1985). En la actualidad, es la única técnica capaz de evaluar la conectividad cerebral en un cerebro humano vivo y por lo tanto posee un enorme potencial para resolver problemas actuales en el área de la neurociencia. Los estándares de resolución de hoy en día de dichas imágenes, permiten hacer diversos análisis sobre conjuntos de fibras de mediano y gran tamaño. Sin embargo, estos análisis pierden precisión en regiones donde las fibras son muy pequeñas en comparación al tamaño del voxel (píxel en tres dimensiones). Consecuentemente, existe la necesidad de incrementar tanto la resolución espacial, angular y temporal de las imágenes dMRI. Dado que el dominio de muestreo de la señal que da origen a este tipo de imágenes, no es solo espacial. El mismo comprende además la intensidad del gradiente de difusión aplicado, la dirección del mismo y el tiempo de difusión (espacio q [Callaghan et al., 1990]). Es por ello que decimos que estas imágenes poseen resolución angular y temporal. La baja relación señal ruido y el tiempo de adquisición de las imágenes dMRI son unos de los principales factores que limitan la resolución de las mismas. Hoy en día, existen escáners que pueden producir imágenes con muy alta resolución. Pero los mismos son muy costosos e imprácticos para escenarios clínicos.

Para obtener detalles más finos sobre las características micro-estructurales a partir de las imágenes de difusión, se puede ajustar un modelo matemático a los datos adquiridos. Uno de los principales objetivos de los modelos de difusión es recuperar información más detallada sobre la orientación de las fibras, haciendo uso del conocimiento a priori que se posee sobre la anatomía de los tejidos neuronales. Entre ellos se encuentra el modelo *Diffusion Tensor Imaging* (DTI). En el cual se representa la señal de difusión con un tensor de segundo orden [Basser et al., 1994]. También existen modelos más complejos como por ejemplo MAPL [Fick et al., 2016]. El mismo pertenece a una familia de modelos que parte del enfoque de representar la señal de difusión con herramientas de análisis armónico. Este extiende el pre-existente modelo llamado *Mean Apparent Propagator* (MAP) (Ozarslan et al., [2013b]), utilizando la norma del Laplaciano de la señal de difusión, como regularización en el ajuste de los coeficientes que MAP define.

Recientemente varias técnicas han sido propuestas para obtener imágenes con alta resolución. Como por ejemplo transferencia de calidad de imágenes (*image quality transfer* en inglés). La cual consiste en explotar la información presente en imágenes adquiridas con alta resolución para mejorar otras con baja resolución [Alexander et al., 2014]. También la técnica conocida como súper-resolución, en la cual se obtiene una imagen con alta resolución utilizando varias imágenes en baja resolución. La adquisición de las imágenes con baja resolución deben seguir un esquema determinado y ser del mismo sujeto (Irani et al. [1993], Robinson et al. [2010]; Greenspan et al 2002; Gholipour et al 2010). Y otras técnicas que por medio de interpolación intentan aumentar la resolución de una imagen a partir de la misma (Manjón et al. [2010]). Estas técnicas pueden mejorar la resolución de las imágenes usando la representación de la señal de difusión tal como la adquieren los escáners. O bien, pueden utilizar algún modelo de la señal de difusión, de los tantos que existen en el área.

Por ejemplo en el trabajo de Alexander et al. [2014] se propone hacer transferencia de calidad de imágenes utilizando algoritmos de aprendizaje automático (*machine learning* del inglés) para reconstruir la imagen con alta calidad. Entrenando a dicho algoritmo con un conjunto de datos de alta calidad. La novedad de este trabajo es que el realce no se hace directamente sobre la

señal de difusión tal como la adquieren los escáners, sino sobre los parámetros de algún modelo de difusión. En particular lo hacen para los modelos DTI y NODDI [Zhang et al., 2012]. En cambio el trabajo de Ning et al. [2016] combina la técnica de súper-resolución con el modelo de difusión *compressed-sensing* [Naidoo et al., 2015]. A diferencia del primer trabajo, utiliza un algoritmo de optimización convexa para reconstruir la imagen con alta calidad. En ambos casos el algoritmo depende fuertemente del modelo seleccionado para representar la señal de difusión.

El objetivo de este trabajo es combinar, por primera vez, la técnica de transferencia de calidad imágenes, con el modelo *Multi-Spherical Diffusion MRI* que toma en cuenta además la dimensión temporal [Fick et al.]. Este modelo es el único al momento que utiliza el análisis armónico para modelar la señal de difusión en función del espacio q y del tiempo de difusión. Para ello plantearemos el objetivo en términos de un problema de optimización convexa, imponiendo además suavidad en la imagen resultante, dado la correlación que existe entre voxels vecinos. Plantearlo de esta manera nos permitirá sacar ventajas de la naturaleza esparza de la señal de difusión. Además usaremos algoritmos de aprendizaje automático para clasificar los tipos de tejidos, para poder hacer un realce más preciso según la región de la imagen. Tanto la complejidad espacial, como temporal de las operaciones necesarias para trabajar con estos volúmenes de datos, representan un desafío computacional, en cuanto a desarrollar un algoritmo eficiente que lleve a cabo el realce buscado. Utilizaremos la base de datos *Human Connectome Project* [Barch et al., 2013], la cual posee gran cantidad de imágenes dMRI con estándares de resolución muy alta.

References

- Daniel C. Alexander, Darko Zikic, Jiaying Zhang, Hui Zhang, and Antonio Criminisi. Image quality transfer via random forest regression: Applications in diffusion MRI. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 8675 LNCS(PART 3):225–232, 2014. ISSN 16113349. doi: 10.1007/978 – 3 – 319 – 10443 – 0_29.
- Deanna M Barch, Gregory C Burgess, Michael P Harms, Steven E Petersen, Bradley L Schlaggar, Maurizio Corbetta, Matthew F Glasser, Sandra Curtiss, Sachin Dixit, Cindy Feldt, Dan Nolan, Edward Bryant, Tucker Hartley, Owen Footer, James M Bjork, Russ Poldrack, Steve Smith, Heidi Johansen-Berg, Abraham Z Snyder, and David C Van Essen. Function in the human connectome: task-fMRI and individual differences in behavior. *NeuroImage*, 80:169–89, October 2013. ISSN 1095-9572. doi: 10.1016/j.neuroimage.2013.05.033. URL <http://www.sciencedirect.com/science/article/pii/S1053811913005272>.
- Peter J. Basser, J. Mattiello, and D. LeBihan. Estimation of the Effective Self-Diffusion Tensor from the NMR Spin Echo. *Journal of Magnetic Resonance, Series B*, 103 (3):247–254, March 1994. ISSN 10641866. doi: 10.1006/jmrb.1994.1037. URL <http://www.sciencedirect.com/science/article/pii/S1064186684710375>.
- P T Callaghan, D MacGowan, K J Packer, and F O Zelaya. High-resolution q-space imaging in porous structures. *Journal of Magnetic Resonance (1969)*, 90(1):177–182, 1990. ISSN 0022-2364. doi: [http://dx.doi.org/10.1016/0022-2364\(90\)90376-K](http://dx.doi.org/10.1016/0022-2364(90)90376-K). URL <http://www.sciencedirect.com/science/article/pii/002223649090376K>.
- Rutger H J Fick, Alexandra Petiet, Mathieu Santin, Stephane Lehericy, Rachid Deriche, and Demian Wassermann. Multi-Spherical Diffusion MRI : Exploring Diffusion Time Using Signal Sparsity.
- Rutger H J Fick, Demian Wassermann, Emmanuel Caruyer, and Rachid Deriche. MAPL: Tissue microstructure estimation using Laplacian-regularized MAP-MRI and its application to {HCP} data. *NeuroImage*, 134:365–385, 2016. ISSN 1053-8119. doi: <http://dx.doi.org/10.1016/j.neuroimage.2016.03.046>. URL <http://www.sciencedirect.com/science/article/pii/S1053811916002512>.
- Michal Irani, Michal Irani, Shmuel Peleg, and Shmuel Peleg. Motion Analysis for Image Enhancement: Resolution, Occlusion, and Transparency. *Journal of Visual Communication and Image Representation*, 4(4):324–335, dec 1993. ISSN 10473203. doi: 10.1006/jvci.1993.1030. URL <http://linkinghub.elsevier.com/retrieve/pii/S1047320383710308>.
- José V. Manjón, Pierrick Coupé, Antonio Buades, Vladimir Fonov, D. Louis Collins, and Montserrat Robles. Non-local MRI upsampling. *Medical Image Analysis*, 14(6):784–792, 2010. ISSN 13618415. doi: 10.1016/j.media.2010.05.010.
- Anushka Naidoo, Kogieleum Naidoo, Nonhlanhla Yende-zuma, and Tanuja N Gengiah. NIH Public Access. 19(2):161–169, 2015. ISSN 00029378. doi: 10.3851/IMP2701.Changes.
- Lipeng Ning, Kawin Setsompop, Oleg Michailovich, Nikos Makris, Martha E. Shenton, Carl Fredrik Westin, and Yogesh Rathi. A joint compressed-sensing and super-resolution approach for very high-resolution diffusion imaging. *NeuroImage*, 125: 386–400, 2016. ISSN 10959572. doi: 10.1016/j.neuroimage.2015.10.061. URL <http://dx.doi.org/10.1016/j.neuroimage.2015.10.061>.
- M Dirk Robinson, Stephanie J Chiu, Cynthia a Toth, Joseph a Izatt, and Joseph Y Lo. Novel Applications of Super-resolution in Medical Imaging. *Super-Resolution Imaging*, pages 383–412, 2010. ISSN 0010-4620. doi: 10.1093/comjnl/bxm075. URL http://duke.edu/~sf59/Medical_SR_chapter10.pdf.

Hui Zhang, Torben Schneider, Claudia A Wheeler-Kingshott, and Daniel C Alexander. NODDI: Practical in vivo neurite orientation dispersion and density imaging of the human brain. *NeuroImage*, 61(4):1000–1016, 2012. ISSN 10538119. doi: 10.1016/j.neuroimage.2012.03.072. URL <http://dx.doi.org/10.1016/j.neuroimage.2012.03.072>.