

El título

Gómez, Leonel Exequiel

August 23, 2016

1 Resumen

1.1 Necesidad que da origen a nuestro objetivo en el área

La Resonancia Magnética de difusión (dMRI en ingles) es una técnica útil para generar imágenes de órganos internos del cuerpo, sin la necesidad de someter al mismo a un procedimiento quirúrgico. Las imágenes construidas por esta técnica están fuertemente relacionadas con la difusión de las partículas de agua en los tejidos. Estas proveen valiosa información sobre la micro estructura de los diferentes tipos de tejidos del cerebro (LeBihan and breton 1985). Los estándares de resolución de hoy en día de dichas imágenes, permiten hacer diversos análisis sobre conjuntos de fibras de mediano y gran tamaño. Sin embargo, estos análisis pierden precisión en regiones donde las fibras son muy pequeñas en comparación al tamaño del voxel (píxel en tres dimensiones). Consecuentemente, existe la necesidad de incrementar la resolución espacial de las imágenes dMRI. Los límites para obtener imágenes con alta resolución están relacionados con el tiempo de adquisición de las mismas y la relación señal ruido (la cual decrece con el tamaño voxel). Hoy en día, existen escáners que pueden producir imágenes con muy alta resolución. Pero los mismos son muy costosos e imprácticos para escenarios clínicos.

1.2 Propuestas que dan origen a nuestro objetivo

Recientemente varias técnicas han sido propuestas para obtener imágenes con alta resolución. Como por ejemplo transferencia de calidad de imágenes (*image quality transfer* en ingles). La cual consiste en explotar la información presente en imágenes adquiridas con alta resolución para mejorar otras con baja resolución [Alexander et al., 2014]. También la técnica conocida como súper-resolución, en la cual se obtiene una imagen con alta resolución utilizando varias imágenes con baja resolución. La adquisición de las imágenes con baja resolución deben seguir un esquema determinado y ser del mismo sujeto (Irani et al. [1993], Robinson et al. [2010]; Greenspan et al 2002; Gholipour et al 2010). Y otras técnicas que por medio de interpolación intentan aumentar la resolución de una imagen con baja resolución (Manjón et al. [2010]). Estas técnicas pueden mejorar la resolución de las imágenes usando la representación de la señal de difusión tal como la adquieren los escáners. O bien pueden utilizar algún modelo de la señal de difusión, de los tantos que existen en el área.

1.3 Explicar técnicas auxiliares a utilizar

Uno de los principales objetivos de los modelos de difusión es recuperar información más detallada sobre la orientación de las fibras en los tejidos del cerebro, a partir de la señal de difusión. Entre ellos se encuentra el modelo *Diffusion Tensor Imaging* (DTI). En el cual se representa la difusión de las partículas de agua con un tensor de segundo orden. También existen modelos mas complejos como por ejemplo MAPL [Fick et al., 2016]. El mismo pertenece a una familia de modelos que parte del enfoque de representar una señal como una sumatoria de otras señales mas básicas. Este extiende el pre-existente modelo llamado *Mean Apparent Propagator* (MAP) (Ozarslan et

al, [2013b]), utilizando la norma del Laplaciano de la señal de difusión, como regularización en el ajuste de los coeficientes que MAP define.

1.4 Otras propuestas con el mismo objetivo

Por ejemplo en el trabajo de Alexander et al. [2014] se propone hacer transferencia de calidad de imágenes utilizando algoritmos de aprendizaje automático (*machine learning* del ingles) para reconstruir la imagen con alta calidad. Entrenando a dicho algoritmo con un conjunto de datos de alta calidad. La novedad de este trabajo es que el realce no se hace directamente sobre la señal de difusión tal como la adquieren los escáners, sino sobre los parámetros de algún modelo de difusión. En particular lo hacen para los modelos DTI (ref dti) y NODDI (ref NODDI). La ventaja de hacer el entrenamiento sobre el modelo en vez de la señal es que se puede utilizar para extrapolar conjuntos de datos que no cumplan con las precondiciones para un modelo determinado. En cambio el trabajo de Ning et al. [2016] combina la técnica de súper-resolución con el modelo *compressed-sensing* [Naidoo et al., 2015] de la señal de difusión. A diferencia del primer trabajo, utiliza un algoritmo de optimización convexa para reconstruir la imagen con alta calidad.

1.5 El objetivo

El objetivo de este trabajo es analizar la aplicación de la técnica de transferencia de calidad, utilizando el modelo *Multi-Spherical Diffusion MRI* que toma en cuenta además la dimensión temporal [Fick et al.]. Tanto la complejidad espacial, como temporal de las operaciones necesarias, representan un desafío computacional, en cuanto a desarrollar un algoritmo eficiente que lleve a cabo el realce buscado. Utilizaremos la base de datos Human Connectome Project, la cual posee gran cantidad de imágenes dMRI estándares de resolución muy alta.

References

- Daniel C. Alexander, Darko Zikic, Jiaying Zhang, Hui Zhang, and Antonio Criminisi. Image quality transfer via random forest regression: Applications in diffusion MRI. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 8675 LNCS(PART 3):225–232, 2014. ISSN 16113349. doi: 10.1007/978 – 3 – 319 – 10443 – 0₂₉.
- Rutger H J Fick, Alexandra Petiet, Mathieu Santin, Stephane Lehericy, Rachid Deriche, and Demian Wassermann. Multi-Spherical Diffusion MRI : Exploring Diffusion Time Using Signal Sparsity.
- Rutger H J Fick, Demian Wassermann, Emmanuel Caruyer, and Rachid Deriche. MAPL: Tissue microstructure estimation using Laplacian-regularized MAP-MRI and its application to {HCP} data. *NeuroImage*, 134:365–385, 2016. ISSN 1053-8119. doi: <http://dx.doi.org/10.1016/j.neuroimage.2016.03.046>. URL <http://www.sciencedirect.com/science/article/pii/S1053811916002512>.
- Michal Irani, Michal Irani, Shmuel Peleg, and Shmuel Peleg. Motion Analysis for Image Enhancement: Resolution, Occlusion, and Transparency. *Journal of Visual Communication and Image Representation*, 4(4):324–335, dec 1993. ISSN 10473203. doi: 10.1006/jvci.1993.1030. URL <http://linkinghub.elsevier.com/retrieve/pii/S1047320383710308>.
- José V. Manjón, Pierrick Coupé, Antonio Buades, Vladimir Fonov, D. Louis Collins, and Montserrat Robles. Non-local MRI upsampling. *Medical Image Analysis*, 14(6):784–792, 2010. ISSN 13618415. doi: 10.1016/j.media.2010.05.010.
- Anushka Naidoo, Kogieleum Naidoo, Nonhlanhla Yende-zuma, and Tanuja N Gengiah. NIH Public Access. 19(2):161–169, 2015. ISSN 00029378. doi: 10.3851/IMP2701.Changes.
- Lipeng Ning, Kawin Setsompop, Oleg Michailovich, Nikos Makris, Martha E. Shenton, Carl Fredrik Westin, and Yogesh Rathi. A joint compressed-sensing and super-resolution approach for very high-resolution diffusion imaging. *NeuroImage*, 125:386–400, 2016. ISSN 10959572. doi: 10.1016/j.neuroimage.2015.10.061. URL <http://dx.doi.org/10.1016/j.neuroimage.2015.10.061>.
- M Dirk Robinson, Stephanie J Chiu, Cynthia a Toth, Joseph a Izatt, and Joseph Y Lo. Novel Applications of Super-resolution in Medical Imaging. *Super-Resolution Imaging*, pages 383–412, 2010. ISSN 0010-4620. doi: 10.1093/comjnl/bxm075. URL http://duke.edu/~sf59/Medical_SR_chapter10.pdf.